# ГРАФОВІ ЙМОВІРНІСНІ МОДЕЛІ

Кореляційний аналіз даних

Сумський державний університет

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції Спірмена

Коефіцієн множинно кореляції До цього аналіз даних проводився за певною ознакою. Але для багатьох дослідів важливим  $\epsilon$  аналіз вза $\epsilon$ мозв'язків одні $\epsilon$ ї або декількох ознак (чи пов'язана зміна одні $\epsilon$ ї ознаки зі зміною іншої).

Існу $\epsilon$  дві категорії зв'язків

- функціональний
- кореляційний або статистичний

Імовірнісні основи обробки даних

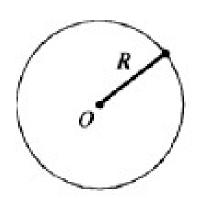
#### Кореляція

Коефіцієн<sup>.</sup>

Коефіцієнт рангової кореляції

Коефіцієн множинно кореляції

#### Функціональний зв'язок



$$C = 2\pi R$$

Імовірнісні основи обробки даних

Кореляція

Кое фіцієнт кореляції

коефіцієні рангової кореляції Спірмена

Коефіцієн<sup>.</sup> множинно кореляції

#### Кореляційний (або статистичний) зв'язок

Чисельному значенню однієї змінної відповідає багато значень іншої змінної.

Наприклад, при закупівлі нового обладнання ( встановленні нового програмного забезпечення) кількість (або якість) продукції повинна збільшуватися.

Але як саме вона залежить від кожного конкретного випадку?

Кількість або сорт мінерального добрива вплива $\epsilon$  на врожайність, але це не означа $\epsilon$ , що конкретному добриву буде відповідати певна кількість врожаю.

Імовірнісні основи обробки даних

#### Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції Спірмена

Коефіцієн множинно кореляції

# Функціональний зв'язок має місце у кожному конкретному досліді

Кореляційний зв'язок характерний лише в середньому для всієї сукупності спостережень

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно кореляції Кореляційні зв'язки - це імовірнісні зміни, які можна вивчати тільки на показних вибірках методами математичної статистики.

Кореляційна залежність - це зміни, які вносять значення однієї ознаки в ймовірність появи різних значень іншої ознаки.

Імовірнісні основи обробки даних

Кореляція

Коефіціє кореляції

Коефіцієнт рангової кореляції

Коефіцієн множинно кореляції Кореляційний аналіз застосовується для кількісної оцінки взаємозв'язку двох наборів даних, представлених в безрозмірному вигляді.

X	3	2	4	5	6	7	8	9	10	11
У	9	7	12	15	17	19	21	23,4	25,6	27,8

Кореляційний аналіз дає можливість встановити, чи асоційовані набори даних по величині.

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієнт множинної кореляції Коефіцієнт кореляції, завжди позначається латинською літерою r, використовується для визначення наявності взаємозв'язку між двома властивостями.

$$r = \frac{\sum (x_i - \overline{x}) (y_i - \overline{y})}{\sqrt{\sum (x_i - \overline{x})^2 \sum (y_i - \overline{y})^2}}$$

Зв'язок між ознаками (за шкалою Чеддока) може бути сильним, середнім і слабким. Тісноту зв'язку визначають за величиною коефіцієнта кореляції, який може приймати значення від -1 до +1 включно.

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції

Коефіцієн множинно

r	0,1-0,3	0,3-0,5	0,5-0,7	0,7-0,9	0,9-1,0	
Зв'язок	слабкий	cepe	дній	сильний		
Сила	слабкий	помірний	помітний	високий	вельми	
зв'язку					високий	

Імовірнісні основи обробки даних

Якщо r=1 або r=-1, то між випадковими величинами X і Y існує лінійна функціональна залежність (Y=K\*X+A).

Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції Спірмена

Коефіцієн множинно кореляції

Імовірнісні основи обробки даних

Якщо r=1 або r=-1, то між випадковими величинами X і Y існує лінійна функціональна залежність (Y=Kst X+A).

Кореляція

Коефіцієнт кореляції

Коефіцієн<sup>.</sup> рангової кореляції Спірмена

Коефіцієн множинно кореляції У проміжних випадках (-1 < r < 1) точки, що відповідають значенням X і Y потрапляють в область, обмежену деяким еліпсом.

Імовірнісні основи обробки даних

Якщо r=1 або r=-1, то між випадковими величинами X і Y існує лінійна функціональна залежність (Y=K\*X+A).

Кореляція

Коефіцієнт кореляції

Коефіцієн<sup>.</sup> рангової кореляції

Коефіцієн множинно кореляції У проміжних випадках (-1 < r < 1) точки, що відповідають значенням X і Y потрапляють в область, обмежену деяким еліпсом.

Тут слід звернути увагу на те, що лінія, вздовж якої групуються точки, може бути не тільки прямою, а мати будь-яку іншу форму: парабола, гіпербола і т. д. У цих випадках треба розглядати так звану, нелінійну (або криволінійну) кореляцію.

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно кореляції

#### Завдання кореляційного аналізу зводиться

- до встановлення напряму (позитивний чи негативний) і форми (лінійної, нелінійної) зв'язку між змінними ознаками,
- до вимірювання тісноти зв'язку,
- до перевірки рівня значущості отриманих коефіцієнтів кореляції.

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієн<sup>і</sup> рангової кореляції

Коефіцієн<sup>.</sup> множинно кореляції У напрямку кореляційний зв'язок може бути

- позитивним ("прямим")
- негативним ("зворотнім")

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієні множинно кореляції У напрямку кореляційний зв'язок може бути

- позитивним ("прямим")
- негативним ("зворотнім")

При позитивній прямолінійній кореляції більш високим значенням однієї ознаки відповідають більш високі значення іншої, а більш низьким значенням однієї ознаки — низькі значення іншої.

Імовірнісні основи обробки даних

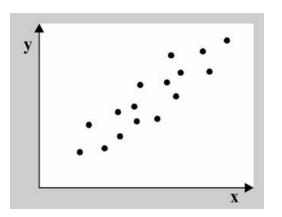
Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції

Коефіцієнт множинної кореляції

#### Позитивний зв'язок



При позитивній кореляції коефіцієнт кореляції має позитивний знак

Імовірнісні основи обробки даних

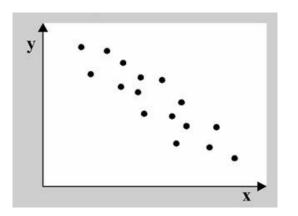
Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції

Коефіцієнт множинної кореляції

## При негативній кореляції співвідношення зворотні



При негативній кореляції коефіцієнт кореляції має негативний знак

Імовірнісні основи обробки даних

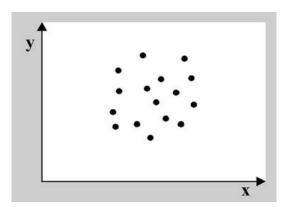
Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієнт множинної кореляції

## Відсутність кореляції



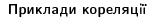
Імовірнісні основи обробки даних

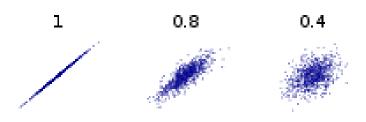
Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно кореляції





Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієнт множинної кореляції



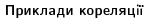
Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

коефіцієні рангової кореляції Спірмена

Коефіцієнт множинної кореляції





Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмона

Коефіцієнмножинно кореляції



Імовірнісні основи обробки даних

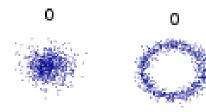
Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції Спірмена

Коефіцієнт множинної кореляції

## Приклади кореляції





Імовірнісні основи обробки даних

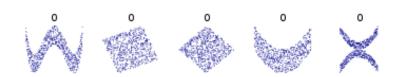
Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції Спірмена

Коефіцієн множинно кореляції

## Приклади кореляції



Імовірнісні основи обробки даних

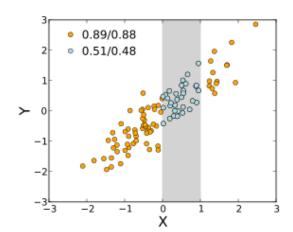
Коефіцієнт кореляції для всього діапазона даних і для окремого інтервалу

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієнт множинної кореляції



Імовірнісні основи обробки даних

Але коефіцієнт кореляції, як загальний статистичний показник, не може замінити візуальний огляд даних.

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн<sup>.</sup> множинно кореляції Наприклад, набір з чотирьох різних пар змінних, які мають однакове середнє значення (7.5), дисперсію (4.12), коефіцієнт кореляції (0.816) і лінія регресії (y=3+0.5x).

Проте розподіл даних дуже відрізняється.

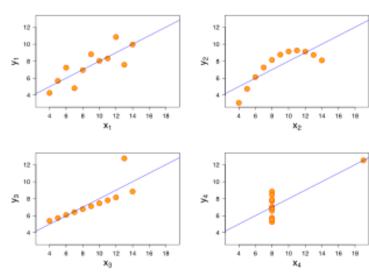
Імовірнісні основи обробки даних

Коредація

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно кореляції



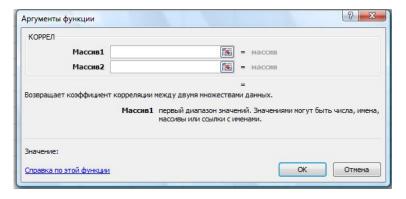
Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієні рангової кореляції Спірмена

Коефіцієн множинно кореляції В програмі Excel для обчислення коефіцієнта кореляції застосовується функції КОРРЕЛ.



Кореляційний аналіз застосовується, якщо для кожного суб'єкта є більше двох змінних вимірювань.

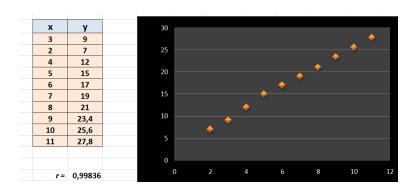
Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієн рангової кореляції

Коефіцієнт множинної кореляції



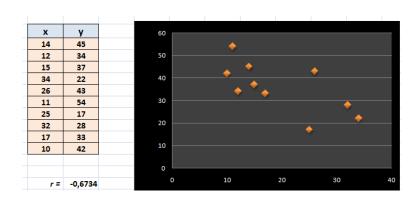
Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції

Коефіцієн<sup>.</sup> множинно кореляції



Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

коефіцієні рангової кореляції Спірмена

Коефіцієн множинно кореляції

#### Етапи кореляційного аналізу

- постановка задачі і вибір ознак;
- збір інформації та її первинна обробка (групування даних, виключення аномальних спостережень, перевірка нормальності одномірного розподілу);
- попередня характеристика взаємозв'язків (аналітичні групування даних, графіки);
- усунення взаємозалежності факторів та уточнення набору показників шляхом розрахунку парних коефіцієнтів кореляції;
- дослідження факторної залежності і перевірка її значущості;
- оцінка результатів аналізу і підготовка рекомендацій щодо їх практичного використання



Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієнмножинно кореляції Лінійний коефіцієнт кореляції Браве-Пірсона

$$r = \frac{\sum (x_i - \overline{x}) (y_i - \overline{y})}{\sqrt{\sum (x_i - \overline{x})^2 \sum (y_i - \overline{y})^2}}$$

$$r = \frac{\sum x_i y_i - \frac{\sum x_i \sum y_i}{n}}{\sqrt{\left(\sum x_i^2 - \frac{(\sum x_i)^2}{n}\right)\left(\sum y_i^2 - \frac{(\sum y_i)^2}{n}\right)}}$$

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн<sup>-</sup> множинно кореляції

#### Кореляційна решітка

y x	4000—4499	4500—4999	5000-5499	5500—5999	6000-6499	6200—6366	7000—7499	7500—7999	8000—8499	fy
4,3-4,4	1	2	1				2			6
4,1-4,2	3	5	l							8
3,9-4,0	7	7	1	1	1	1				17
3,7-3,8	7	6	6	5						24
3,5-3,6	3	. 2	7	6	1					19
3,3-3,4	1	- 3	2	4	1	2	1	1	2	17
3,13,2			3	1	1	1			1	7
2,9-3,0	1					1				2
fx -	23	25	20	16	4	5	3	1	3	100

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно кореляції

#### Кореляційна решітка

будується при великій кількості даних (наприклад n=100).

На двох сторонах квадрату (зверху по горизонталі) і зліва по вертикалі записують значення класів обох рядів.

Дані при вивченні ознак треба внести у відповідні клітинки решітки, що відповідають одразу двом ознакам.

Імовірнісні основи обробки даних

Щоб вважати отриманий коефіцієнт кореляції достовірним, він повинен перевищувати табличне значення.

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно кореляції Як і для критерія  $\chi^2$  таблиця побудована для різних рівнів значущості (за стовбчиками) та степеней свободи.

$$df = n - 2$$

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієнт множинної кореляції

		P		
df	0,05	0,01		
5	0,75	0,87		
6	0,71	0,83		
7	0.67	0,80		
8	0,63	0,77		
9	0,60	0,74		
10	0,58	0,71		
11	0,55	0,68		
12	0,53	0,66		
13	0,51	0,64		
14	0,50	0,62		
15	0,48	0,61		
16	0,47	0,59 .		
17	0,46	0,58		
18	0,44	0,56		
19	0,43	0,55		
20	0.49	0.54		

Імовірнісні основи обробки даних

Кореляція

кореляціі Коефіцієнт

Коефіцієн рангової кореляції Спірмена

Коефіцієні множинно кореляції

#### Коефіцієнт рангової кореляції Спірмена

Метод рангової кореляції Спірмена дозволяє визначити тісноту (силу) і напрям кореляційного зв'язок між двома ознаками або двома профілями (ієрархіями) ознак.

$$r_{xy}^{S} = 1 - \frac{6 \cdot \sum (d_x - d_y)^2}{n \cdot (n^2 - 1)},$$

де  $d_{x}$ ,  $d_{y}$  — ранги показників x, y; n — кількість кореляційних пар.

Імовірнісні основи обробки даних

Кореляція

кореляції кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн<sup>1</sup> множинно кореляції Для підрахунку рангової кореляції Спірмена необхідно розташувати двома рядами значення, які можуть бути проранжовані. Спочатку показники ранжуються окремо по кожній з ознак. Як правило, меншому значенню ознаки нараховується менший ранг.

За кожною змінною має бути представлено не менше 5 спостережень.

В ідеалі обидва кореляційні ряди повинні представляти собою дві послідовності неоднакових значень.

Імовірнісні основи обробки даних

Кореляція

Коефіцієн

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно

x	55	45	43	47	47	51	48	60	53	50
у	26	20	25	22	27	28	16	15	18	24

Імовірнісні основи обробки даних

Кореляція

Коефіцієн кореляції

Коефіцієнт рангової кореляції <u>Сп</u>ірмена

Коефіцієнт множинної

x	d_x	у	d_y
43	1	15	1
45	2	16	2
46	3	18	3
47	4	20	4
48	5	22	5
50	6	24	6
51	7	25	7
53	8	26	8
55	9	27	9
60	10	28	10

Імовірнісні основи обробки даних

Кореляція

Коефіцієн<sup>.</sup>

Коефіцієнт рангової кореляції Спірмена

x	d_x	у	d_y
55	9	26	9
45	2	20	4
43	1	25	7
46	3	22	5
47	4	27	8
51	7	28	10
48	5	16	2
60	10	15	1
53	8	18	3
50	6	24	6

Імовірнісні основи обробки даних

Кореляція

Коефіцієн<sup>.</sup> кореляції

Коефіцієнт рангової кореляції Спірмена

x	d_x	у	d_y
55	9	26	9
45	2	20	4
43	1	25	7
47	3,5	22	5
47	3,5	27	8
51	7	28	10
48	5	16	2
60	10	15	1
53	8	18	3
50	6	24	6

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт

Коефіцієнт рангової кореляції Спірмена

$$r_{xy}^{S} = 1 - \frac{6 \cdot \sum (d_x - d_y)^2}{n \cdot (n^2 - 1)},$$

$$r_{w}^{g} = 1 - \frac{6.186,5}{10.99} = 1 - \frac{1119}{990} \approx 1 - 1,13 \approx -0,13$$

Імовірнісні основи обробки даних

Коефіцієнт рангової кореляції також має межі 1 і -1.

рангової кореляції

Коефіцієнт Спірмена

Коефіцієнт рангової кореляції Спірмена обчислюється значно простіше, ніж коефіцієнт кореляції Браве-Пірсона при одних і тих же вихідних даних, оскільки при обчисленні використовуються ранги, що представляють собою зазвичай цілі числа.

Потім, обчисливши значення, необхідно визначити достовірність знайденого коефіцієнта кореляції, порівнявши його фактичне значення з табличним.

Імовірнісні основи обробки даних

Якщо

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Коефіцієн множинно корепації

$$r_{\Phi} \ge r_{st}$$

то можна говорити про те, що між ознаками спостерігається достовірна взаємозв'язок.

Якщо

$$r_{\Phi} < r_{st}$$

то між ознаками спостерігається недостовірна кореляційний взаємозв'язок.

Імовірнісні основи обробки даних

Достовірність коефіцієнта рангової кореляції теж можна оцінювати за допомогою таблиці для звичайного коефіцієнта кореляції але для n > 8.

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції Спірмена

Імовірнісні основи обробки даних

Кореляція

Коефіцієнт кореляції

Коефіцієнт рангової кореляції <u>Сп</u>ірмена

Коефіцієнт множинноі кореляції

	P		
df	0,05	0,01	
5	0,75	0,87	
6	0,71	0,83	
7	0.67	0,80	
8	0,63	0,77	
9	0,60	0,74	
10	0,58	0,71	
11	0,55	0,68	
12	0,53	0,66	
13	0,51	0,64	
14	0,50	0,62	
15	0,48	0,61	
16	0,47	0,59 .	
17	0,46	0,58	
18	0,44	0,56	
19 -	0,43	0,55	
20	0,42	0,54	

df = n - 2



# Коефіцієнт множинної кореляції

Імовірнісні основи обробки даних

Кореляція

кореляції

Коефіцієнт рангової кореляції

X	y	Z
2,5	3,8	11,4
2,2	6,1	12,3
2,1	6,7	12,9
2,4	6,8	13,4
2,7	7,2	14,2
2,2	7,4	14,5
5,6	8,5	12,9
4,5	8,8	15,6
4,7	7,6	15,2
3,5	8,2	16,4
3,8	6,4	17,8
3,5	9,4	16,9

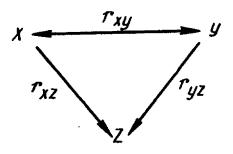
# Коефіцієнт множинної кореляції

Імовірнісні основи обробки даних

Кореляція

кореляції

Коефіцієнт рангової кореляції



# Коефіцієнт множинної кореляції

Імовірнісні основи обробки даних

Кореляція

кореляції

Коефіцієнт рангової кореляції

$$r_{xy \cdot z} = \frac{\frac{r_{xy} - r_{xz} \cdot r_{yz}}{\sqrt{(1 - r_{xz}^2)(1 - r_{yz}^2)}}}{r_{xz \cdot y} = \frac{\frac{r_{xz} - r_{xy} \cdot r_{zy}}{\sqrt{(1 - r_{xy}^2)(1 - r_{zy}^2)}}}{\sqrt{(1 - r_{xy}^2)(1 - r_{yx}^2)}}}$$

$$r_{zy \cdot x} = \frac{r_{zy} - r_{zx} \cdot r_{yx}}{\sqrt{(1 - r_{zx}^2)(1 - r_{yx}^2)}}$$