


# МАШИНЕ НАВЧАННЯ

## Класичне навчання. Навчання з вчителем




Лекція №6

# Методи класифікації


## Метод опорних векторів (SVM)

Найбільш популярний метод класичної класифікації. Ним класифікували вже **все**: типи рослин, лиця на фотографіях, документи за тематиками. Багато років він був головною відповіддю на питання «який би мені взяти класифікатор».



Ідея SVM — провести полосу пряму між категоріями таким чином, що відстані від неї до граничного об'єкта кожного класу була максимальною.

# Метод опорних векторів (SVM) в задачах класифікації



Розглянемо задачу бінарної класифікації, в якій об'єктам з  $X = \mathbb{R}^n$  (об'єкти описуються  $n$  числовими признаками) відповідає один з двох класів  $Y = \{-1, +1\}$ .

Нехай задана навчальна вибірка пар "об'єкт-відповідь":  $(x_i, y_i), i = 1 \dots \ell$ .  
Необхідно побудувати алгоритм класифікації  $a(x): X \rightarrow Y$ .

## Розділяюча гіперплощина

У просторі  $\mathbb{R}^n$  рівняння  $\langle w, x \rangle - b = 0$  при заданих  $w$  та  $b$  визначає гіперплощину, що розділяє  $\mathbb{R}^n$  на два класи:  $C_1$  та  $C_2$ :


$$\begin{cases} \langle w, x \rangle - b > 0, & \forall x \in C_1 \\ \langle w, x \rangle - b < 0, & \forall x \in C_2 \end{cases}$$

або


$$\begin{cases} \langle w, x \rangle - b < 0, & \forall x \in C_1 \\ \langle w, x \rangle - b > 0, & \forall x \in C_2 \end{cases}$$

$w$  — вектор нормалі до гіперплощини


$\frac{b}{\|w\|}$  — відстань від гіперплощини  
до початку координат




# Метод опорних векторів (SVM) в задачах класифікації: Лінійно роздільна вибірка



**Відступ (Margin)** — характеристика, яка оцінює, наскільки об'єкт «занурений» у свій клас, наскільки типовим представником свого класу він є. Чим менше значення відступу  $M_i$ , тим ближче об'єкт  $x_i$  підходить до границі класів і тим вище стає ймовірність помилки. Відступ  $M_i$  **від'ємний** лише тоді, коли алгоритм класифікації  $a(x_i)$  допускає помилку на об'єкті  $x_i$ .



# Метод опорних векторів (SVM) в задачах класифікації: Лінійно роздільна вибірка



Для лінійного класифікатора відступ визначається рівнянням:

$$M_i(w, b) = y_i(\langle x_i, w \rangle - b)$$

Для лінійно роздільної вибірки існує така гіперплощина, відступ від якої до кожного об'єкта є позитивним:

$$\exists w, b: \quad M_i(w, b) = y_i(\langle x_i, w \rangle - b) > 0, \quad i = 1 \dots \ell$$


**Задача:** пошукувати таку розділяючу гіперплощину, щоб об'єкти навчальної вибірки знаходились на найбільшій відстані від неї.

## Нормування

При множенні  $w$  та  $b$  на константу  $C \neq 0$  рівняння  $\langle x_i, Cw \rangle - Cb = 0$  визначає ту ж саму гіперплощину, що й  $\langle x_i, w \rangle - b = 0$ .

Для зручності проведемо нормування: оберемо константу  $C$  таким чином, щоб  $\min M_i(w, b) = 1$ .

# Метод опорних векторів (SVM) в задачах класифікації: Лінійно роздільна вибірка



В кожному з двох класів знайдеться хоча б один "граничний" об'єкт навчальної вибірки, відступ якого дорівнює цьому мінімуму: в іншому випадку можна було б змістити гіперплощину в бік класу з більшим відступом, тим самим збільшити мінімальну відстань від гіперплощини до об'єктів навчальної вибірки.

Позначимо "граничний" об'єкт з класу  $+1$  як  $x_+$ , а з класу  $-1$  як  $x_-$ .

$$x_+: \langle x, w \rangle - b = +1$$

$$x_-: \langle x, w \rangle - b = -1$$

$$M_+(w, b) = (+1)(\langle x_+, w \rangle - b) = 1$$

$$M_-(w, b) = (-1)(\langle x_-, w \rangle - b) = 1$$


Нормування дозволяє обмежити розділяючу полосу між класами:

$$x: \{-1 < \langle x, w \rangle - b < 1\}$$

Всередині якої не может лежати жоден об'єкт навчальної вибірки.

Ширина полоси це проекція вектора  $(x_+ - x_-)$  на  $w$ :

$$\frac{\langle x_+ - x_-, w \rangle}{\|w\|} = \frac{M_+ + M_-}{\|w\|} = \frac{2}{\|w\|} \rightarrow \max \Rightarrow \|w\| \rightarrow \min.$$



$\|w\| = \langle w, w \rangle -$   
скалярний добуток

# Метод опорних векторів (SVM) в задачах класифікації: Лінійно роздільна вибірка




Максимальність ширини розділяючої полоси

$$\frac{2}{\|w\|} \rightarrow \max \Rightarrow \|w\| \rightarrow \min.$$

$\|w\| = \langle w, w \rangle$  –  
скалярний добуток

Постановка задачі оптимізації в термінах квадратичного програмування:

$$\begin{cases} \|w\| \rightarrow \min_{w,b} \\ M_i(w, b) \geq 1, \quad i = 1 \dots \ell \end{cases}$$






# Метод опорних векторів (SVM) в задачах класифікації

## Умови Каруша-Кунна-Таккера

задача нелінійного програмування з обмеженнями:



$$\begin{cases} f(x) \rightarrow \min_{x \in X} \\ g_i(x) \leq 0, & i = 1 \dots m \\ h_j(x) = 0, & j = 1 \dots k \end{cases}$$


Якщо  $x$  — точка локального мінімуму при накладених обмеженнях, то існують такі множники  $\mu_i, i = 1 \dots m$  та  $\lambda_j, j = 1 \dots k$ , що для функції Лагранжа  $\mathcal{L}(x; \mu, \lambda)$  виконуються умови:

$$\begin{cases} \frac{d\mathcal{L}}{dx} = 0, \mathcal{L}(x; \mu, \lambda) = f(x) + \sum_{i=1}^m \mu_i g_i(x) + \sum_{j=1}^k \lambda_j h_j(x) \\ g_i(x) \leq 0, & h_j(x) = 0 & \text{(вихідні обмеження)} \\ \mu_i \geq 0 & & \text{(двійкові обмеження)} \\ \mu_i g_i(x) = 0 & & \text{(доповнюючі обмеження)} \end{cases}$$

При цьому шукана точка є сідловою точкою функції Лагранжа: мінімумом по  $x$  та максимумом по двійковим змінним  $\mu$ .



# Метод опорних векторів (SVM) в задачах класифікації



Для нашої задачі оптимізації:

$$\begin{cases} \|w\| \rightarrow \min_{w,b} \\ M_i(w, b) \geq 1, \quad i = 1 \dots \ell \end{cases}$$

За теоремою ККТ маємо Лагранжیان

$$\mathcal{L}(w, b, \lambda_1, \dots, \lambda_\ell) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^{\ell} \lambda_i \{y_i(\langle x_i, w \rangle - b) - 1\}$$


Похідні від Лагранжиану за параметрами

$$\begin{cases} \frac{\partial \mathcal{L}(w, b, \lambda_1, \dots, \lambda_\ell)}{\partial w} = 0; \\ \frac{\partial \mathcal{L}(w, b, \lambda_1, \dots, \lambda_\ell)}{\partial b} = 0; \\ \lambda_i \geq 0; \\ \lambda_i = 0 \text{ або } \{y_i(\langle x_i, w \rangle - b) - 1\} = 0 \end{cases}$$

З перших двох рівнянь знаходимо:

$$\begin{cases} w = \sum_{i=1}^{\ell} \lambda_i y_i x_i; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0 \end{cases}$$

# Метод опорних векторів (SVM) в задачах класифікації



Підставляючи отримані обмеження в функцію Лагранжа отримуємо постановку двійкової задачі, яка залежить лише від двійкових змінних  $\lambda$ :

$$\begin{cases} \mathcal{L}(\lambda) = \sum_{i=1}^{\ell} \lambda_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle \\ 0 \leq \lambda_i \leq C, \quad i = 1 \dots \ell \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0 \end{cases}$$

$$\begin{aligned} \mathcal{L}(\lambda) &= \sum_{i=1}^{\ell} \lambda_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle = \\ &\quad \{(H)_{ij} = y_i y_j \langle x_i, x_j \rangle\} \\ &= \sum_{i=1}^{\ell} \lambda_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j (H)_{ij} = \lambda + \frac{1}{2} \lambda^T H \lambda \end{aligned}$$

Це задача квадратичного програмування:


# Метод опорних векторів (SVM) в задачах класифікації

Метод градієнтного спуску:


$$\mathcal{L}(\lambda) = \lambda + \frac{1}{2} \lambda^T H \lambda$$

Невідомі параметри Лагранжа:

$$\lambda^{t+1} = \lambda^t + \eta \frac{\partial \mathcal{L}}{\partial \lambda}$$



Навчальна вибірка





За отриманими  $\lambda_i$  розв'язок прямої задачі:

$$\begin{cases} w = \sum_{i=1}^{\ell} \lambda_i y_i x_i; \\ b = \begin{cases} (\langle w, x_i \rangle - y_i) \\ \text{med}(\langle w, x_i \rangle - y_i) \end{cases} \forall i: \lambda_i > 0, M_i = 1 \end{cases}$$

Лінійний класифікатор

$$a(x) = \text{sign} \left( \sum_{i=1}^{\ell} \lambda_i y_i \langle x_i, x \rangle - b \right)$$

# Метод опорних векторів (SVM) в задачах класифікації: Лінійно не роздільна вибірка



В даних можуть бути певні викиди, що приводить до нечітких меж між класами. Необхідно послабити обмеження, дозволяючи де-яким об'єктам попадати в середину розділюючої полоси та на "територію" іншого класу.


Відступ

$$M_i(w, b) = y_i(\langle x_i, w \rangle - b)$$

Функція втрат (Loss function)


$$L = \max(0, 1 - M_i)$$

Інакше всі помилки рівноправні



# Неперервні апроксимації порогової функції втрат

Часто використовувані неперервні функції втрат  $L(M)$



$$V(M) = (1 - M)_+$$

$$H(M) = (-M)_+$$

$$L(M) = \log_2(1 + e^{-M})$$

$$Q(M) = (1 - M)^2$$

$$S(M) = 2(1 + e^M)^{-1}$$

$$E(M) = e^{-M}$$

$$[M < 0]$$

– кусочно-лінійна (SVM);

– кусочно-лінійна (Hebb's rule);

– логарифмічна (LR);




– квадратична (FLD);

– сигмоїдна (ANN);

– експоненціальна (AdaBoost);

– порогова функція втрат

# Метод опорних векторів (SVM) в задачах класифікації: Лінійно не роздільна вибірка




- Для кожного об'єкта віднімемо від відступу позитивну величину  $\xi_i$ , яле будемо вимагати, що ці введені поправки були мінімальними. Це приведе до задачі, що має назву *SVM з м'яким відступом* (англ. *soft-margin SVM*):

$$\begin{cases} \frac{1}{2} \|w\| + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w,b,\xi} \\ M_i(w, b) \geq 1 - \xi_i, \quad i = 1 \dots \ell \\ \xi_i \geq 0, \quad i = 1 \dots \ell \end{cases}$$

- Еквівалентна задача безумовної мінімізації:

$$\frac{1}{2} \|w\| + C \sum_{i=1}^{\ell} (1 - M_i(w, b))_+ \rightarrow \min_{w,b}$$

# Метод опорних векторів (SVM) в задачах класифікації



За теоремою Каруша—Куна—Таккера, поставлена задача мінімізації еквівалентна двійковій задачі пошуку сідлової точки функції Лагранжа:

$$\mathcal{L}(w, b, \xi; \lambda, \eta) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, b) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C)$$

$\lambda_i$  — змінні, двійкові до обмежень  $M_i \geq 1 - \xi_i$


$\eta_i$  — змінні, двійкові до обмежень  $\xi_i \geq 0$

Необхідні умови існування сідлової точки функції Лагранжа:

$$\begin{cases} \frac{d\mathcal{L}}{dw} = 0, & \frac{d\mathcal{L}}{db} = 0, & \frac{d\mathcal{L}}{d\xi} = 0 \\ \xi_i \geq 0, & \lambda_i \geq 0, & \eta_i \geq 0, & i = 1 \dots \ell \\ \lambda_i M_i(w, b) = 0 \implies \lambda_i = 0 \text{ або } M_i(w, b) = 1 - \xi_i, & i = 1 \dots \ell \\ \eta_i \xi_i = 0 \implies \eta_i = 0 \text{ або } \xi_i = 0, & i = 1 \dots \ell \end{cases}$$



# Метод опорних векторів (SVM) в задачах класифікації



Відступ (margin) об'єкта  $x_i$  від розділяючої гіперплощини :

$$M_i(w, b) = y_i(\langle x_i, w \rangle - b)$$

Функція Лагранжа:

$$\mathcal{L}(w, b, \xi; \lambda, \eta) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, b) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C)$$


Необхідні умови існування сідлової точки функції Лагранжа:

$$\left\{ \begin{array}{l} \frac{d\mathcal{L}}{dw} = w - \sum_{i=1}^{\ell} \lambda_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^{\ell} \lambda_i y_i x_i \\ \frac{d\mathcal{L}}{db} = \sum_{i=1}^{\ell} \lambda_i y_i = 0 \Rightarrow \sum_{i=1}^{\ell} \lambda_i y_i = 0 \\ \frac{d\mathcal{L}}{d\xi_i} = -\lambda_i - \eta_i + C = 0 \Rightarrow \eta_i + \lambda_i = C, \quad i = 1 \dots \ell \end{array} \right.$$

Зауважимо, що  $\eta_i \geq 0$ ,  $\lambda_i \geq 0$ ,  $C > 0$ , тому, з останнього обмеження отримуємо  $0 \leq \eta_i \leq C$ ,  $0 \leq \lambda_i \leq C$ .

# Метод опорних векторів (SVM) в задачах класифікації

Система умов Каруша-Куна-Таккера:




$$\left\{ \begin{array}{l} w = \sum_{i=1}^{\ell} \lambda_i y_i x_i; \quad \sum_{i=1}^{\ell} \lambda_i y_i = 0; \quad M_i(w, b) \geq 1 - \xi_i \\ \xi_i \geq 0, \quad \eta_i \geq 0, \quad \lambda_i \geq 0, \quad \eta_i + \lambda_i = C \\ \lambda_i M_i(w, b) = 0 \Rightarrow \lambda_i = 0 \text{ або } M_i(w, b) = 1 - \xi_i, \quad i = 1 \dots \ell \\ \eta_i \xi_i = 0 \Rightarrow \eta_i = 0 \text{ або } \xi_i = 0, \quad i = 1 \dots \ell \end{array} \right.$$

Діапазон значень  $\lambda_i$  які відповідають обмеженням на величину відступу дозволяють поділити об'єкти навчальної вибірки на три типи:

1.  $\lambda_i = 0 \Rightarrow \eta_i = C; \xi_i = 0; M_i \geq 1$  — периферійні (неінформативні) об'єкти: вони знаходяться в своєму класі, класифікуються вірно та не впливають на вибір розділяючої гіперплощини;
2.  $0 < \lambda_i < C \Rightarrow 0 < \eta_i < C; \xi_i = 0; M_i = 1$  — опорні граничні об'єкти: знаходяться чітко на границі розділяючої полоси на стороні свого класу;
3.  $\lambda_i = C \Rightarrow \eta_i = 0; \xi_i > 0; 0 < M_i < 1$  — об'єкти-порушники: знаходяться всередині розділяючої полоси;
4.  $\lambda_i = C \Rightarrow \eta_i = 0; \xi_i > 0; M_i < 0$  — помилки: не вірно класифіковані об'єкти, які знаходяться на боці не свого класу

# Метод опорних векторів (SVM) в задачах класифікації

Перехід до більш зручного опису



$$x = (x_1, x_2, \dots, x_n)$$

	A	B	C	D	E
1	Radius_mean	Texture_mean	Perimeter_mean	Area_mean	Diagnosis
2	17.99	10.38	122.8	100	1
3	20.57	17.77	132.9	132	1
4	19.69	21.25	130	120	1
5	11.42	20.38	77.58	386.	1
6	20.29	14.34	135.1	129	1
7	12.45	15.7	82.57	477.	1
8	18.25	19.98	119.6	104	1
9	13.71	20.83	90.2	577.	1
10	13	21.82	87.5	519.	1
11	12.46	24.04	83.97	475.	1
12	16.02	23.24	102.7	797.	1
13	15.78	17.89	103.6	78	1
14	14.61	15.69	92.68	664.	0
15	12.76	13.37	82.29	504.	0
16	11.54	10.72	73.73	409.	0
17	8.597	18.6	54.09	221.	0
18	12.49	16.85	79.19	481.	0
19	12.18	14.08	77.25	461.	0
10	18.22	18.87	118.7	102	1
21	9.042	18.9	60.07	244.	0

$$x_{n+1} = 1; w_0 = -b$$

$$[\langle x_i, w \rangle - b]_{i=1 \dots n} \rightarrow [\langle x_i, w \rangle]_{i=1 \dots n+1}$$

Відступ

$$M_i(w) = y_i \langle x_i, w \rangle$$

Задача оптимізації

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} (1 - M_i(w))_+ \rightarrow \min_w$$

Розв'язується методом  
градієнтного спуску

$$y = \{-1, 1\}$$

# Метод градієнтного спуску в задачах машинного навчання

Функціонал якості  $f(w) \rightarrow \min_w$

$$f(w) = \frac{1}{2} \|w\|^2 + C \frac{1}{\ell} \sum_{i=1}^{\ell} (1 - M_i(w))_+$$

Для всіх об'єктів навчальної вибірки

$$f(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left[ \frac{1}{2} \|w\|^2 + C(1 - y_i \langle w, x_i \rangle)_+ \right]$$




Розрахунок наступного значення ваг  $w$   
за методом градієнтного спуску:

$$w_i = w_i - \eta \frac{1}{\ell} \nabla f(w)$$


$\eta$  — крок навчання

Похідна від функціоналу якості

$$\nabla f(w) = \frac{df}{dw} = \frac{1}{\ell} \sum_{i=1}^{\ell} \begin{cases} w, & \text{if } \max(1 - y_i \langle w, x_i \rangle)_+ = 0 \\ w - C y_i x_i, & \text{otherwise} \end{cases}$$



# Метод градієнтного спуску в задачах машинного навчання




Розрахунок наступного значення ваг  $w$   
за методом градієнтного спуску


$$w_i = w_i - \eta \frac{1}{\ell} \sum_{i=1}^{\ell} \begin{cases} w, & \text{if } \max(1 - y_i \langle w, x_i \rangle)_+ = 0 \\ w - C y_i x_i, & \text{otherwise} \end{cases}$$

Вплив параметра  $C$

Велике значення параметра  $C$   
слабка регуляризація



Мале значення параметра  $C$   
сильна регуляризація







# Метод градієнтного спуску в задачах машинного навчання


Розрахунок наступного значення ваг  $w$   
за методом градієнтного спуску

$$w_i = w_i - \eta \frac{1}{\ell} \sum_{i=1}^{\ell} \begin{cases} w, & \text{if } \max(1 - y_i \langle w, x_i \rangle)_+ = 0 \\ w - C y_i x_i, & \text{otherwise} \end{cases}$$

Вплив швидкості навчання  $\eta$



# Метод опорних векторів (SVM) в задачах класифікації



## Нелінійне узагальнення (*kernel trick*)

- Для лінійно нероздільної вибірки  $X = \mathbb{R}^n$  існує спрямляючий простір  $\mathcal{H}$  (більшої розмірності) з функцією переходу  $\psi: X \rightarrow \mathcal{H}$
- Скалярний добуток  $\langle x_1, x_2 \rangle$  у просторі  $X$  замінюється скалярним добутком  $\langle \psi(x_1), \psi(x_2) \rangle$  у **гільбертовому** просторі  $\mathcal{H}$  з визначеним скалярним добутком.
- Це надає можливість замінити скалярний добуток у просторі  $X$  на **ядро** — функцію, що є скалярним добутком у де-якому просторі  $\mathcal{H}$ . Замість підбору  $\psi$  можна підбирати безпосередньо ядро  $K(x_i, x_j) = \langle \psi(x_1), \psi(x_2) \rangle$ .

Постановка задачі з застосуванням ядер приймає вигляд


$$\begin{cases} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j K(x_i, x_j) \rightarrow \min_{\lambda} \\ 0 \leq \lambda_i \leq C, \quad i = 1 \dots \ell \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0 \end{cases}$$

Лінійний класифікатор з ознаками  $f_i(x) = K(x, x_i)$ :

$$a(x) = \text{sign} \left( \sum_{i=1}^{\ell} \lambda_i y_i K(x, x_i) \right)$$



# Метод опорних векторів (SVM) в задачах класифікації



## Приклади ядер

1. Квадратичне ядро  $\dim \mathcal{H} = \frac{1}{2}n(n+1)$ :

$$K(x, x') = \langle x, x' \rangle^2$$

2. Поліноміальне ядро,  $\dim \mathcal{H} = C_{n+d-1}^d$ :

$$K(x, x') = \langle x, x' \rangle^d$$

3. Поліноміальне ядро:

$$K(x, x') = (\langle x, x' \rangle + 1)^d$$

4. Сигноїдне ядро:


$$K(x, x') = \text{th}(k_1 \langle x, x' \rangle - k_0), \quad k_0, k_1 > 0$$

5. Гаусове ядро (RBF ядро):

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$


линейное

$$\langle x, x' \rangle$$




полиномиальное



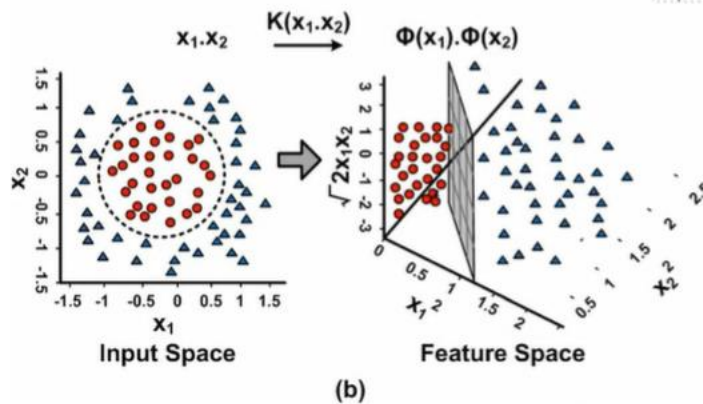


$$(\langle x, x' \rangle + 1)^d, \quad d=3$$




гауссовское (RBF)

$$\exp(-\gamma \|x - x'\|^2)$$







Линейное ядро:  $K_{\text{linear}}(\vec{x}_1; \vec{x}_2) = (\vec{x}_1; \vec{x}_2)$



Гауссово ядро:  $K_{\text{rbf}}(\vec{x}_1; \vec{x}_2) = \exp(-\gamma \|\vec{x}_1 - \vec{x}_2\|^2)$




Полиномиальное ядро:  $K_{\text{poly}}(\vec{x}_1; \vec{x}_2) = (\gamma(\vec{x}_1; \vec{x}_2) + r)^d$



Сигмоидное ядро:  $K_{\text{sigmoid}}(\vec{x}_1; \vec{x}_2) = \tanh(\gamma(\vec{x}_1; \vec{x}_2) + r)$

# Метод опорних векторів (SVM) в задачах класифікації



## Переваги та недоліки SVM

### Переваги класичного SVM :

- Завдання опуклого квадратичного програмування добре вивчене і має єдине рішення.
- Метод опорних векторів еквівалентний двошаровій нейронній мережі, де число нейронів на прихованому шарі визначається автоматично як число опорних векторів.
- Принцип оптимальної роздільної гіперплощини призводить до максимізації ширини смуги, що розділяє, а отже, до більш впевненої класифікації.

### Недоліки класичного SVM:

- Нестійкість до шуму: викиди у вихідних даних стають опорними об'єктами-порушниками та безпосередньо впливають на побудову роздільної гіперплощини.
- Не описані загальні методи побудови ядер та спрямовуючих просторів, що найбільш підходять для конкретного завдання.
- Немає відбору ознак.
- Необхідно підбирати константу  $C$  за допомогою крос-валідації.



Дякую за увагу