


# МАШИНЕ НАВЧАННЯ

## Класичне навчання. Навчання без вчителя



Лекція №8

# Навчання без учителя

**Навчання без вчителя** (Unsupervised Learning) було створено в 90-і. На практиці використовується рідше ніж навчання з учителем.

Проте бувають задачі, де просто немає вибору:

реальні розмічені дані — рідкість.

Приклад: написати класифікатор автобусів:

йти на вулицю й фотографувати мільйон різних автобусів.

**Коли немає розмітки використовують навчання без учителя.**

Навчання без учителя, все ж таки, частіше використовують як метод аналізу даних, а не як основний алгоритм навчання.

**Основний алгоритм:**

Вкидуємо до алгоритму дані та спостерігаємо:

- Чи є кластери?
- Чи є залежності?
- Чи є асоціації?

Задачі навчання без учителя:


- **зменшення розмірності (узагальнення) — збирає конкретні ознаки в абстракції більш високого рівня**
- **кластеризація — розділяє об'єкти за незалежною ознакою**
- **асоціація — шукає закономірності у потоці замовлень**

# Зменшення розмірності (Dimension Reduction или Feature Learning)

Збирає конкретні ознаки в абстракції вищого рівня

Практична користь їх методів полягає в тому, що ми можемо об'єднати кілька ознак в одну і отримати абстракцію. Наприклад, собаки з трикутними вухами, довгими носами та великими хвостами поєднуються у корисну абстракцію «вівчарки». Так, ми втрачаємо інформацію про конкретні вівчарки, але нова абстракція набагато корисніша за ці зайві деталі. Плюс, навчання на меншій кількості розмірностей йде сильно швидше. Сьогодні використовують для:

- Визначення тематики та пошуку схожих документів
- Аналіз фейкових зображень
- Ризик-менеджмент




Популярні алгоритми:

Метод головних компонентів (PCA), Сингулярне розкладання (SVD), Латентне розміщення Діріхле (LDA), Латентно-семантичний аналіз (LSA)

# Зменшення розмірності

## Метод головних компонент (PCA)





**Метод головних компонент** (МГК, англ. principal component analysis, PCA) — метод факторного аналізу в статистиці, який використовує ортогональне перетворення множини спостережень з можливо пов'язаними змінними (сутностями, кожна з яких набуває різних числових значень) у множину змінних без лінійної кореляції, які називаються **головними компонентами**.

Метод головних компонент — один з основних способів зменшити розмірність даних, втративши найменшу кількість інформації. Винайдений Карлом Пірсоном у 1901 році та доповнений і розширений Гарольдом Хотелінгом в 1933 р. Застосовується в багатьох галузях, зокрема, в економетриці, біоінформатиці, обробці зображень, для стиснення даних, у суспільних науках.

Обчислення головних компонент може бути зведене до обчислення сингулярного розкладу матриці даних або до обчислення власних векторів і власних чисел коваріаційної матриці початкових даних. Іноді метод головних компонент називають *перетворенням Кархунена — Лоева* або *перетворенням Хотеллінга* (англ. Hotelling transform).



# Зменшення розмірності

## Метод головних компонент (PCA)



Y є надлишковим.

Для кластеризації достатньо X




Не існує проєкції яка б дозволила розділити дані




# Зменшення розмірності

## Метод головних компонент (PCA)



Однак, якщо проєціювати дані на лінійну комбінацію двох осей то можна легко кластеризувати дані





- Знаючи залежності ми можемо виразити кілька ознак через одну і працювати з більш простою моделлю. Звичайно, уникнути втрат інформації не вдасться, але мінімізувати її допоможе метод PCA.
- Висловлюючись суворіше, даний метод апроксимує  $n$ -розмірну хмару спостережень до еліпсоїда (теж  $n$ -вимірного), півосі якого і будуть майбутніми головними компонентами. І про проєкції на такі вісі (зниження розмірності) зберігається найбільше інформації.



# Зменшення розмірності

## Метод головних компонент (PCA)

У цій вибірці у нас є дві ознаки, що сильно корелюють одна з одною. За допомогою алгоритму PCA ми зможемо легко знайти ознаку-комбінацію і виразити обидві ці ознаки однією новою.




Для опису випадкової величини використовуються моменти:

- мат. очікування – центр тяжіння» (положення) випадкової величини
- дисперсія – "розмір" (розкид) випадкової величини.


Сам процес проектування на вектор ніяк не впливає на значення середніх, оскільки для мінімізації втрат інформації наш вектор має проходити через центр нашої вибірки.

Тому можна відцентрувати вибірку - лінійно змістити її так, щоб середні значення ознак дорівнювали нулеві. Це дуже спростить подальші обчислення (хоча можна обійтися і без центрування).



# Зменшення розмірності

## Метод головних компонент (РСА)



Для опису форми випадкового вектора потрібна коваріаційна матриця: матриця, у якої  $(i, j)$ -елемент є кореляцією ознак  $(x_i, x_j)$ .

Коваріація двох випадкових величин:

$$\text{Cov}(x_i, x_j) = E \left[ (x_i - E(x_i)) \cdot (x_j - E(x_j)) \right] = E(x_i, x_j) - E(x_i)E(x_j)$$

У даному випадку  $E(x_i) = E(x_j) = 0$

$$\text{Cov}(x_i, x_j) = E(x_i, x_j); \quad \text{Cov}(x_i, x_i) = \text{Var}(x_i)$$

Таким чином, в нашій матриці по діагоналі будуть дисперсії, а в інших комірках – коваріації відповідних пар ознак. Через симетричність коваріації матриця теж буде симетричною

$$\Sigma = \begin{bmatrix} \text{Var}(x_i) & \text{Cov}(x_i, x_j) \\ \text{Cov}(x_i, x_j) & \text{Var}(x_j) \end{bmatrix}$$

Тепер треба знайти такий вектор  $u$  (у нашому випадку тільки один,  $u^T u = 1$ ), при якому буде максимальною дисперсія проекції нашої вибірки  $u^T X$ .


Дисперсія проекції на вектор

$$\text{Var}(u^T X) = E((u^T X) \cdot (u^T X)^T) = E(u^T X \cdot X^T u) = u^T E(X \cdot X^T) u = u^T \Sigma u$$



# Зменшення розмірності

## Метод головних компонент (РСА)



Необхідно максимізувати  $u^T \Sigma u$  при обмеженні  $u^T u = 1$

Використовуємо метод множників Лагранжа:

$$\mathcal{L} = u^T \Sigma u + \lambda(1 - u^T u)$$

Максимум досягається при  $\frac{\partial \mathcal{L}}{\partial u} = 0$ :  $\Sigma u = \lambda u \rightarrow \lambda = u^T \Sigma u$

**Отже:**  $u$  – власний вектор матриці  $\Sigma$  з максимальним власним значенням  $\lambda$

Таким чином, напрямок максимальної дисперсії у проекції завжди збігається з власним вектором, що має максимальне значення, що дорівнює величині цієї дисперсії.

І це справедливо також для проекцій на більшу кількість вимірювань – дисперсія (коваріаційна матриця) проекції на  $m$ -мірний простір буде максимальною у напрямку  $m$  власних векторів, що мають максимальні власні значення.

З проекцією зручно працювати, будувати на її основі гіпотези та розробляти моделі. Але іноді корисно розкодувати, наприклад, виявлені викиди, щоб подивитися, що за ними стоїть.

# Власні значення та власні вектори

**Означення.** Нехай  $A$  - квадратна матриця розміру  $n \times n$  над полем  $F$ . Число  $\lambda \in F$  називається власним значенням матриці  $A$ , якщо існує ненульовий вектор  $v$  такий, що

$$Av = \lambda v.$$

В цьому випадку вектор  $v$  називається власним вектором матриці  $A$  з власним значенням  $\lambda$ .

Аналогічно можна дати означення власного вектора лінійного оператора.

**Означення.** Нехай  $f : V \rightarrow V$  - лінійний оператор. Число  $\lambda \in F$  називається власним значенням  $f$ , якщо існує ненульовий вектор  $v \in V$  такий, що

$$f(v) = \lambda v.$$

В цьому випадку вектор  $v$  називається власним вектором лінійного оператора  $f$  з власним значенням  $\lambda$ .

**Означення.** Характеристичним многочленом матриці  $A$  називається  $\chi_A(\lambda) = \det(A - \lambda E)$ , або докладніше

$$\chi_A(\lambda) = \det \begin{pmatrix} a_{11} - \lambda & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} - \lambda & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} - \lambda \end{pmatrix}.$$

# Власні значення та власні вектори

**Означення.** Характеристичним многочленом матриці  $A$  називається  $\chi_A(\lambda) = \det(A - \lambda E)$ , або докладніше

$$\chi_A(\lambda) = \det \begin{pmatrix} a_{11} - \lambda & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} - \lambda & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} - \lambda \end{pmatrix}.$$

**Теорема.** Власні значення матриці  $A$  є в точності коренями її характеристичного многочлена  $\chi_A(\lambda)$

**Доведення.** Якщо вектор  $v$  є власним вектором матриці  $A$  з власним числом  $\lambda$ , то

$$Av = \lambda v,$$

це фактично система лінійних рівнянь, яку можна переписати таким чином

$$Av - \lambda Ev = 0,$$

$$(A - \lambda E)v = 0.$$

Це однорідна система лінійних рівнянь, яка має ненульовий розв'язок. Це буває тоді і лише тоді, коли матриця  $A - \lambda E$  вироджена, тобто,  $\det(A - \lambda E) = 0$ . 😊 **Успішно доведено.**

# Власні значення та власні вектори

## Приклад

$$A = \begin{pmatrix} 1 & 4 & 1 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{pmatrix},$$

$$\begin{aligned} |A - \lambda E| &= (1 - \lambda) \cdot \begin{vmatrix} 2 - \lambda & 2 \\ 0 & 3 - \lambda \end{vmatrix} - 4 \cdot \begin{vmatrix} 0 & 2 \\ 0 & 3 - \lambda \end{vmatrix} + 1 \cdot \begin{vmatrix} 0 & 2 - \lambda \\ 0 & 0 \end{vmatrix} = \\ &= (1 - \lambda) \cdot (2 - \lambda) \cdot (3 - \lambda). \end{aligned}$$

## Розв'язання

$$(1 - \lambda) \cdot (2 - \lambda) \cdot (3 - \lambda) = 0,$$

$$\lambda_1 = 1,$$

$$\lambda_2 = 2,$$

$$\lambda_3 = 3.$$

## Python with Numpy

```
>>> A = np.matrix("1 4 1; 0 2 2 ; 0 0 3")
>>> A
matrix([[1, 4, 1],
        [0, 2, 2],
        [0, 0, 3]])
>>> w, v = np.linalg.eig(A)
>>> w
array([1., 2., 3.]
```

# Власні значення та власні вектори

Приклад

$$A = \begin{pmatrix} 7 & 3 \\ -5 & -1 \end{pmatrix}.$$

$$|A - \lambda E| = \begin{vmatrix} 7 - \lambda & 3 \\ -5 & -1 - \lambda \end{vmatrix} = (7 - \lambda) \cdot (-1 - \lambda) - (-15) = \lambda^2 - 6\lambda + 8.$$

$$\lambda^2 - 6\lambda + 8 = 0,$$

$$\lambda_{1,2} = \frac{6 \pm \sqrt{36 - 32}}{2} = \frac{6 \pm 2}{2},$$

$$\lambda_1 = 4,$$

$$\lambda_2 = 2.$$

$$\begin{pmatrix} 7 & 3 \\ -5 & -1 \end{pmatrix} \times \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 4 \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix},$$

$$\begin{cases} 7 \cdot x_1 + 3 \cdot x_2 = 4 \cdot x_1 \\ -5 \cdot x_1 - 1 \cdot x_2 = 4 \cdot x_2 \end{cases}$$

$$\begin{cases} 3 \cdot x_1 + 3 \cdot x_2 = 0 \\ -5 \cdot x_1 - 5 \cdot x_2 = 0 \end{cases}$$

$$x_2 = -x_1.$$

$$\lambda_1(x_1, -x_1);$$
$$\lambda_2 \left( x_1, -\frac{5}{3}x_1 \right)$$

$$\begin{pmatrix} 7 & 3 \\ -5 & -1 \end{pmatrix} \times \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 2 \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix},$$

$$\begin{cases} 7 \cdot x_1 + 3 \cdot x_2 = 2 \cdot x_1 \\ -5 \cdot x_1 - 1 \cdot x_2 = 2 \cdot x_2 \end{cases}$$

$$\begin{cases} 5 \cdot x_1 + 3 \cdot x_2 = 0 \\ -5 \cdot x_1 - 3 \cdot x_2 = 0 \end{cases}$$

$$x_2 = -\frac{5}{3} \cdot x_1.$$



Дякую за увагу